

2026 年第五届全国大学生数据统计与分析竞赛

题目 B：零售销售额的预测与数据分析

零售行业作为国民经济的重要组成部分，其销售额的波动与变化直接反映了消费市场的景气程度，准确预测零售销售额对于企业经营决策、供应链管理、营销规划等方面具有至关重要的意义。零售销售额的预测与数据分析在商业运营与市场研究领域价值突出，无论是对零售企业、供应链合作伙伴，还是行业研究机构，都具有不可忽视的实践价值。

对于零售企业而言，准确预测销售额是制定经营策略的核心依据。当通过数据分析判断销售额呈上升趋势时，企业可提前优化库存布局、扩大采购规模、规划营销活动，抓住消费增长的红利；若预测销售额将出现下滑，企业可及时调整产品结构、控制运营成本、优化渠道布局，降低经营风险。此外，结合销售额与不同产品、区域、客群的关联分析，企业可精准定位高价值业务板块，优化资源配置，实现盈利水平的稳步提升。

对供应链合作伙伴与物流服务商来说，零售销售额的波动会直接传导至供应链全链路，准确的预测和分析有助于实现供应链的协同优化。供应商可依据销售额预测结果规划生产节奏，避免产能过剩或供应短缺；物流服务商可提前调配仓储与运力资源，优化配送路径，在保障订单履约效率的同时，降低物流运营成本。

零售销售额的变化是消费市场趋势的直观体现，是行业研究与政策制定的重要参考指标。通过对零售销售额的长期跟踪与分析，研究机构可精准捕捉消费升级、需求结构变化的行业趋势，为零售行业的数字化转型、模式创新提供数据支撑；政策制定部门可通过零售销售额的变化判断消费市场的运行状况，为制定促消费、稳增长的相关政策提供科学依据。同时，零售销售额还与居民收入、消费信心、宏观经济环境等变量高度相关，研究其与这些变量的联动关系，有助于深入理解消费市场的运行逻辑，为宏观经济政策的调整提供有力支持。

本次比赛提供了美国零售企业订单销售数据集（**data.csv**），参赛者需要运用数据统计与分析技能，深入挖掘数据信息，以更好地理解零售销售额的变化规律并进行精准预测。

数据集说明

文件名为 **data.csv**，包含了 2022-2025 年美国零售企业全量订单的核心数据，具体涵盖订单基础信息、客户与地理信息、产品分类信息、销售核心指标四大类字段，完整覆盖了零售订单从下单到履约的全链路核心维度，可支撑多维度的销售分析与预测建模。

任务要求

参赛者需要完成以下四个问题，以深入分析零售销售额的数据特征、影响因素并完成预测建模：

问题 1：数据基本统计与可视化（20 分）

1. 对数据集进行初步统计与分析，计算销售额的核心基本统计量，包括均值、中位数、标准差、最小值和最大值，同时统计总销售额、总订单数、有效客户数、产品总数等核心业务指标。

2. 绘制销售额随时间变化的趋势折线图（可按日、月、年维度聚合），直观展示零售销售额的整体走势与周期波动特征。

3. 分析销售额在不同维度（如年份、季度、月份、地理区域、产品大类、客户细分、发货模式）的分布与波动情况，并对核心特征进行简要描述。

问题 2：销售影响因素相关性分析（25 分）

1. 从数据集中选取可能影响零售销售额的核心维度（时间维度、地理维度、产品维度、客户维度、物流维度），量化分析各维度与销售额的关联程度与影响显著性。

2. 绘制多维度销售额对比可视化图表（如相关系数热力图、分类柱状图、分布箱线图、区域销售额地图等），直观展示各因素对销售额的影响差异。

3. 根据相关性与显著性分析结果，简要说明哪些因素对零售销售额的影响最为显著，识别出驱动销售额增长的核心因素与抑制销售的关键短板。

问题 3：建立销售额预测模型（30 分）

1. 结合数据特征与业务逻辑，选择合适的建模方法（如时间序列分析、线性回归、决策树、随机森林等），构建零售销售额预测模型。

2. 按照时间维度将数据集划分为训练集和测试集（建议 2022-2024 年数据为训练集，2025 年数据为测试集），使用训练集完成模型训练与参数优化，在测试集上完成销售额预测。

3. 全面评估模型的预测效果，计算均方误差（MSE）、平均绝对误差（MAE）、平均绝对百分比误差（MAPE）等核心评估指标，并结合业务场景对模型的优势与不足进行简要分析。

问题 4：未来销售预测与经营策略建议（25 分）

1. 使用优化完成的预测模型，对未来一段时间（如 2026 年全年、分季度）的零售销售额进行滚动预测，给出分维度的预测结果与趋势判断。

2. 结合销售额预测结果、核心影响因素分析结论，为该零售企业提供一份可落地的经营策略建议，涵盖产品布局优化、区域营销规划、客户分层运营、物流履约优化、库存管理提升等核心业务方向，明确给出不同场景下的经营动作建议。

评分标准

1. 每个问题将根据完成的准确性、完整性和分析的深度进行评分，无合理分析支撑的结果将不得分。

2. 问题 1-3 中，正确的统计计算、合理的可视化呈现、严谨的分析解释将获得对应分数；问题 4 中，准确的未来预测结果、贴合业务的策略建议、规范的分析报告将获得对应分数。

3. 总分为 100 分，四个问题分别占 20 分、25 分、30 分、25 分。

附件数据详细说明

以下是对数据集 `data.csv` 中各列数据名称的详细解释，按业务逻辑分为四大类：

一、订单基础信息类

1.Row ID

- 含义：数据行唯一标识，为每条订单明细数据分配的唯一序号，用于数据定位与去重。

2.Order ID

- 含义：订单唯一编号，同一订单的多条明细数据共享同一个订单 ID，是订单维度聚合分析的核心标识。

3.Order Date

- 含义：订单下单日期，格式为 DD/MM/YYYY（如 08/11/2024 表示 2024 年 11 月 8 日），是时间序列分析的核心基准维度。

4.Ship Date

- 含义：订单发货日期，格式为 DD/MM/YYYY，反映订单的履约时效，可用于分析物流周期对销售的影响。

5.Ship Mode

- 含义：发货模式，分为 Standard Class（标准级）、Second Class（二级）、First Class（一级）、Same Day（当日达）四类，反映订单的物流服务等级。

二、客户与地理信息类

6.Customer ID

- 含义：客户唯一编号，用于识别不同的消费主体，是客户分层、复购分析的核心标识。

7.Customer Name

- 含义：客户名称，与客户 ID 一一对应，用于客户维度的明细分析。

8.Segment

- 含义：客户细分类型，分为 Consumer（个人消费者）、Corporate（企业客户）、Home Office（家庭办公客户）三类，反映客户的消费属性与需求特征。

9.Country

- 含义：订单所属国家，本数据集所有订单均来自美国，是地理维度分析的基础层级。

10.City

- 含义：订单所属城市，反映消费的城市级地理分布，可用于城市层级的销售差异分析。

11.State

- 含义：订单所属州，美国的州级行政单位，是区域销售分析的核心维度之一。

12.Postal Code

- 含义：邮政编码，对应订单的精准地理定位，可用于更细粒度的区域销售分析。

13.Region

- 含义：订单所属大区，分为 **South**（南部）、**West**（西部）、**Central**（中部）、**East**（东部）四类，是美国零售行业通用的区域划分标准，为大区域销售策略制定提供支撑。

三、产品信息类

14.Product ID

- 含义：产品唯一编号，用于识别不同的 **SKU**，是产品维度分析的核心标识。

15.Category

- 含义：产品大类，分为 **Furniture**（家具）、**Office Supplies**（办公用品）、**Technology**（科技产品）三类，是产品结构分析的核心维度。

16.Sub-Category

- 含义：产品子分类，在产品大类下的二级细分品类，共 17 个子分类，可用于更精准的产品品类分析。

17.Product Name

- 含义：产品名称，与产品 **ID** 一一对应，包含产品的品牌、型号、核心特征等明细信息，用于产品级的销售分析。

四、销售核心指标类

18.Sales

- 含义：该条订单明细的销售额，单位为美元，是本次分析与预测的核心目标指标，反映了单条产品明细的销售规模。

注意事项

1. **数据时间范围**：数据集的订单时间跨度为 2022 年 1 月 3 日至 2025 年 12 月 30 日，共 4 个完整年度的订单数据，时间序列分析需严格遵循时间先后顺序，避免数据泄露。

2. **缺失值处理**：数据集中仅 Postal Code 字段存在 11 条缺失值，其余字段均无缺失，分析前需对缺失值进行合理处理，并说明处理逻辑。

3. **数据聚合逻辑**：同一 Order ID 下可能包含多条 Product ID 的明细数据，订单维度的聚合分析需注意去重，避免重复统计订单数、客户数等指标。

4. **行业惯例**：零售销售额通常具有明显的月度、季度、年度周期特征，同时受区域经济、产品品类、客群结构、物流时效等因素显著影响，分析与建模需结合零售行业的通用业务逻辑。

5. **模型合理性**：预测建模需优先选择可解释性强、贴合业务场景的方法，避免过度追求复杂模型而忽略业务逻辑的合理性，模型评估需同时关注统计指标与业务落地价值。